# Tables de hachage

---

## Récapitulatif

**Tableaux :** accès efficace

**Tableaux triés :** accès efficace, recherche très efficace (recherche dichotomique)

**Listes :** insertion / délétion efficace

**Question :** peut-on avoir une structure de données qui soit performante pour toutes les opérations ?

**Spoiler alert :** oui, **les tables de hachage** qui sont un peu moins efficace que les tableaux pour l'accès mais beaucoup plus que les listes et un peu moins efficace que les listes pour l'insertion / délétion mais beaucoup plus que les tableaux.

**Bonus :** la structure est *très* efficace pour la recherche

---

## Clef

**Objectif :** fournir un identifiant, appelé une **clef**, unique à une entité

Par exemple :

- Donner un numéro unique à chaque étudiant dans une université
- Donner un numéro unique à des livres dans une bibliothèque

**But :** rechercher rapidement si une entité existe en leur attribuant une **clef**

**Problème :** que faire s'il peut y avoir un grand nombre de valeurs pour la **clef** ?

Par exemple, à l'Université de Lorraine, la clef (le numéro d'étudiant) est de la forme : 32219666 (8 chiffres)

**Solution non réaliste :** utiliser un tableau de 100000000 indexé de 0 à 99999999

---

## Fonction de hachage

### Notations

- L'ensemble des valeurs possibles des clefs s'appelle **l'univers de clefs ($U$)**
- On n'utilise généralement qu'un sous-ensemble **$K \subseteq U$** des clefs

**Important :** les clefs sont un choix du programmeur.

**Question :** que faire si on dispose d'un tableau de taille $n$ pour stocker les éléments avec $n << |K| << |U|$ ?

**Fonction de hachage :** une fonction $h: U \rightarrow [0\dots n-1]$

**Utilisation :** déterminer l'indice où ranger l'élément liée une clef

---

## Table de hachage

Un tableau de taille $n$ où un objet $x$ associé à une clef $k$ est stocké à l'indice $h(k)$

les opérations suivantes sont définies pour les tables de hachage :

- **RECHERCHE :** pour une clef $k$ retourner une référence sur un objet de la table de hachage ayant $k$ comme clef ou indiquer qu'un tel objet n'existe pas
- **INSERTION :** étant donné un nouvel objet $x$, ajouter $x$ à la table de hachage
- **SUPPRESSION :** pour une clef $k$, retirer un objet dont la clef est $k$ de la table de hachage si un tel objet existe

---

## Efficacité des opérations

- **Recherche :** efficace (quasi-constant) si la fonction de hachage et la taille de la table de hachage sont biens choisies et les données ne sont pas pathologiques
- **Insertion :** aussi efficace (constant) qu'un tableau
- **Suppression :** efficace (quasi-constant) si la fonction de hachage et la taille de la table de hachage sont biens choisies et les données ne sont pas pathologiques

---

## Quand utiliser une table de hachage ?

Une table de hachage s'utilise si

- on a besoin d'une recherche rapide
- on travaille sur un ensemble d'objets qui change de manière dynamique
- on peut définir une clef unique pour chaque élément

---

## Exemple d'application : déduplication

**Situation :** Un *grand nombre* de données arrivent une à la fois sous forme d'un flux, par exemple :

- lecture des données dans un large fichier stocké sur un disque ;
- parcourir le web et traiter des milliards de pages web ;
- suivre des paquets de données passant par un routeur de réseaux à grande vitesse ;
- suivez les visiteurs d'un site web.

**But :** le but est de garder qu'une seule occurence de chaque clef et de l'objet associé.

**Exemple :** dans le suivi de visiteur, l'adresse IP peut servir de clef et on ne garde qu'une fois chaque adresse IP.

---

## Algorithme pour la déduplication avec une table de hachage

Quand un nouvel objet $x$ associé à une clef $k$ arrive :

1. Utiliser **RECHERCHE** pour vérifier si la table de hachage contient déjà un objet avec la clef $k$
2. Si ce n'est pas le cas, utiliser **INSERTION** pour ajouter $x$ à la table de hachage

---

## Exemple d'application : problème 2-SUM

**Données**

- un tableau $A$ de $n$ entiers
- un entier cible $t$

**Objectif**

Déterminer s'il existe deux nombres $x, y$ dans $A$ tel que $x + y = t$

ou de manière équivalente

Déterminer s'il existe deux indices $i$ et $j$ dans $[1,\dots, n]$ tel que $A[i] + A[j] = t$

**Algorithme brute-force**

Essayer toutes les combinaisons possibles pour $x$ et $y$

**coût** : de l'ordre de $n^2$ *itérations*

**Question :** peut-on faire mieux ?

---

## Tentative 1

**Observation :** pour une valeur $x$ fixée, $y$ vaut forcément $t - x$

**Principe :** recherchez dans le tableau $t - x$

```
Pour i = 1 à n faire
  y := t - A[i]
  si A contient y alors // recherche séquentielle
    retourner "oui"
retourner "non"
```

**coût :** de l'ordre de $n^2$ *itérations*

**Question :** peut-on faire mieux ?

---

## Tentative 2

**Observation :** on peut améliorer la recherche en utilisant un tableau trié

**Principe :** trier le tableau et utiliser une recherche dichotomique

```
trier A // par exemple par le tri fusion
Pour i = 1 à n faire
  y := t - A[i]
  si A contient y alors // recherche dichotomique
    retourner "oui"
retourner "non"
```

**coût :** de l'ordre de $n\log n$ *itérations*

**Remarque :** $n\log n$ est **significativement** mieux que $n^2$

**Question :** peut-on faire mieux ?

---

## Tentative 3

**Observation :** améliorer la recherche

**Principe :** utilisation d'une table de hachage où la clef est l'entier

```
H := une table de hachage vide

Pour i = 1 à n faire
  INSERER A[i] dans H

Pour i = 1 à n faire
  y := t - A[i]
  si H contient y alors // utilisation de RECHERCHER
    retourner "oui"

retourner "non"
```

**coût :** de l'ordre de $n$ itérations

**Remarque :** $n$ est **significativement** mieux que $n\log n$ et un ordre de grandeur plus petit que $n^2$

---

## Implémentation : idées de haut niveau

Les principales idées à envisager sont

- les fonctions de hachage qui assigne à chaque clef un indice dans la table
- les **collisions** : cela arrive quand la fonction de hachage attribue le même indice à deux clefs différentes
- les stratégies de résolution des collisions : que faire quand une collision intervient

**Remarque sur la taille de la table de hachage :**

- le choix de la taille de la table est lié à la taille de $U$ ou de $K$

- si $U$ ou $K$ sont de taille raisonnable, on peut utiliser un tableau de taille $|U|$ ou $|K|$ $\rightarrow$ le coût des opérations dépend alors de cette taille
- Si $|K|$ (et donc $|U|$) est trop grand, on peut utiliser une taille de table plus petite et ranger les objets dans des listes chaînées pour chaque indice $\rightarrow$ **RECHERCHE** et **SUPPRESSION** deviennent un peu moins efficace

---

## Fonctions de hachage

une fonction de hachage $h : U \rightarrow {0, 1, 2, \dots, n-1}$ affecte chaque clef de $U$ à une position dans un tableau de taille $n$

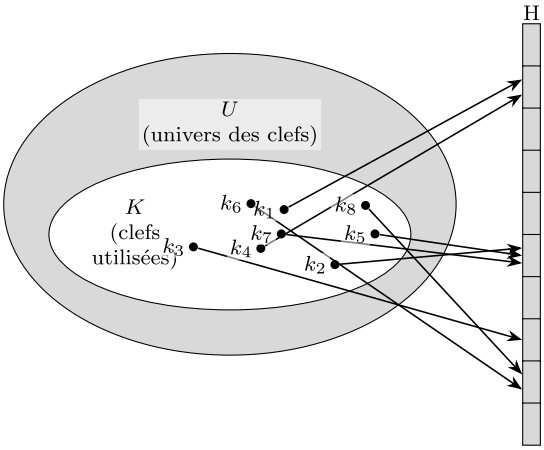


---

## Collision

**Définition :** deux clefs $k_1$ et $k_2$ de $U$ sont en *collision* pour une fonction de hachage $h$ si $h(k_1) = h(k_2)$.

**Principe des tiroirs de Dirichlet:** si $n$ chaussettes occupent $m$ tiroirs et si $n > m$ alors au moins un tiroir doit contenir strictement plus d'une chaussette

**Conséquence :** les collisions sont inévitables ; il n'existe pas de fonction de hachage permettant d'éviter les collitsions si $|U| est strictement plus grand que la taille de la table de hachage

**Question :** que faire quand une collision se produit ?

---

## Résolution des collisions : chaînage ou addressage fermé

1. Garder une liste chaînée pour chaque position de la table de hachage
2. Pour RECHERCHER / INSERER / SUPPRIMER un objet avec une clef $k$, on effectue l'opération correspondante dans la liste chaînée se trouvant dans $H[h(k)]$

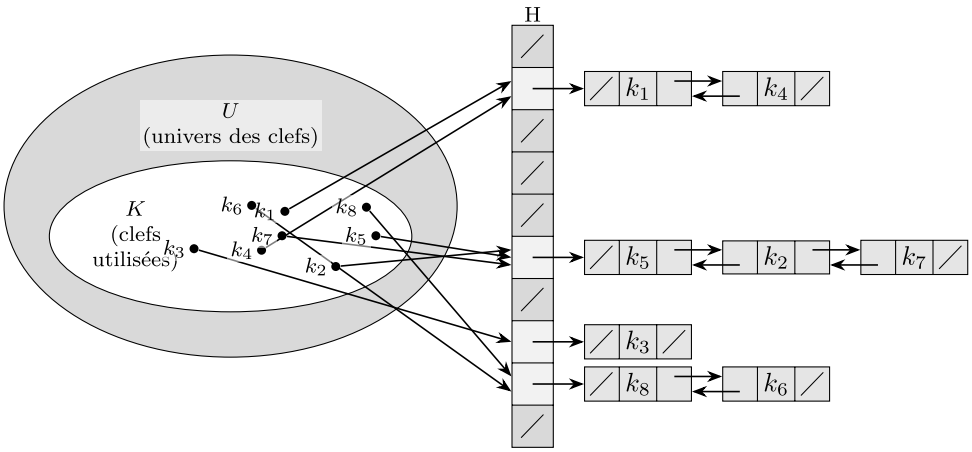


---

## Résolution des collisions : addressage ouvert

**Principe :** Pour un objet associé à une clef $k$ si la position $h(k)$ est déjà occupée, on recherche une place libre par **sondage**

**Exemple :** on souhaite ajouter **ROY** (qui est la clef et la valeur) ; $h(ROY) = 2$

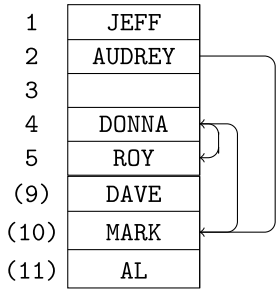


---

## Sondage

**INSERTION :** si la position est libre, on ajoute l'objet à cette position sinon on recherche une autre position par **sondage**

**RECHERCHE / SUPPRESSION :** il faut parcourir les positions dans le même ordre jusqu'à tomber sur l'objet recherché ou sur une position vide

**Définition de la fonction de sondage :** $h'(k, i)$ avec

- $k$ : la clef
- $i$ : le numéro de la tentative
- il faut que $h'(k, 0) = h(k)$
- $h'$ doit permettre (si nécessaire de parcourir toutes les positions de la table)

**Exemple: sondage linéaire** $h'(k, i) = (h(k) + a\times i) \mod n$ avec $a \in \N^+$

**Exemple: double hachage** $h'(k, i) = (h(k) + i \times h_2(k)) \mod n$ avec $h_2$ une fonction de hachage

---

## Conclusions

- le choix de la taille de la table de hachage a une influence sur l'efficacité pour éviter les collisions

**$\Rightarrow$ Compromis entre l'espace mémoire et le nombre de collisions**

- le choix de la fonction de hachage a une très forte influence sur l'efficacité pour éviter les collisions
- le choix du sondage dans un adressage ouverta une influence sur l'efficacité

**$\Rightarrow$ la définition de ces fonctions est difficile et la structure est présente dans la plupart des librairies des langages modernes**